




SÃO
PAULO
TECH
SCHOOL

Aula

Data Cleaning Data Standardization Data Enrichment



Prof. : Marcelo Rosim

Data Cleaning e Standardization


Vamos falar sobre um tópico crucial no mundo da Ciência de Dados : *Limpeza*, *Padronização* e *Enriquecimento* de Dados (Data Cleaning, Standardization e Enrichment).

Data Cleaning e Standardization



Imaginem a seguinte situação: você está construindo um sistema de recomendação para um **e-commerce** ou desenvolvendo um modelo de **Machine Learning** para prever o tempo. Você coleta uma quantidade massiva de dados, mas o que acontece se esses dados estiverem cheios de erros, inconsistências ou formatos diferentes?

É exatamente aí que entra a importância da limpeza e padronização



Data Cleaning e Standardization

Dados sujos ou inconsistentes podem levar a que



- **Modelos de Machine Learning imprecisos:** Um modelo treinado com dados ruins aprenderá padrões incorretos e fará previsões falhas. É o famoso **lixo entra, lixo sai**.
- **Decisões de negócios equivocadas:** Análises baseadas em dados incorretos podem levar a estratégias e investimentos desastrosos.
- **Dificuldade na integração de dados:** Ao combinar dados de diferentes fontes, inconsistências podem impedir que as informações sejam unificadas corretamente
- **Perda de tempo e recursos:** Equipes gastam tempo valioso depurando problemas causados por dados de baixa qualidade.
- **Problemas de segurança e conformidade:** Dados sensíveis podem ser expostos ou não estarem em conformidade com regulamentações se não forem devidamente tratados.

Data Cleaning e Standardization

Em Resumo.....



A **qualidade dos seus dados** está diretamente ligada à *qualidade* dos seus *resultados*. A limpeza e padronização são etapas fundamentais para garantir que seus dados sejam confiáveis, consistentes e úteis.

Limpeza de Dados - Data Cleaning

Técnicas...

- Tratamento de Valores Ausentes (Missing Values)
- Tratamento de Outliers (Valores Extremos)
- Tratamento de Dados Duplicados
- Correção de Erros de Digitação e Inconsistências de Formato

Limpeza de Dados - Data Cleaning

Tratamento de Valores Ausentes (Missing Values)

- Falta de dados são um dos problemas mais comuns. Ocorrem por diversas razões: falha na coleta, dados não informados, erro de digitação, etc.
- **Estratégias de Tratamento :**
 - **Extração de Dados:** Verificar o comportamento/regra dos dados na origem e tratar na ETL/ELT os dados, para minimizar ausência deles
 - **Enriquecimento de Dados:** Verificar se o dado ausente existe em alguma outra fonte de dados para corrigir as ausências desta extração

Limpeza de Dados - Data Cleaning

Tratamento de Valores Ausentes (Missing Values)

- **Estratégias de Tratamento : Imputação *****
 - **Valor constante:** Preencher com um valor fixo (0, "Desconhecido"). Útil para categorias ou quando o valor 0 faz sentido.
 - **Média/mediana/moda:**
 - **Média:** Dados numéricos, preencher com a média da coluna. Sensível a outliers.
 - **Mediana:** Dados numéricos, preencher com a mediana da coluna. Mais robusta a outliers.
 - **Moda:** Para dados categóricos, preencher com o valor mais frequente.
 - **Interpolação:** Preencher valores ausentes com base nos valores adjacentes, seguindo uma lógica linear por exemplo.
 - **Usando modelos preditivos:** Treinar um modelo (Regressão Linear) para prever os valores ausentes com base em outras colunas. Mais complexo, mas pode gerar melhores resultados.

Limpeza de Dados - Data Cleaning

Tratamento de Valores Ausentes (Missing Values)

- **Estratégias de Tratamento : Remoção**
 - **Remover linhas:** Se uma linha tem muitos valores ausentes ou se a quantidade de linhas com N/A é pequena em relação ao dataset total. **Cuidado:** pode levar à perda de informações valiosas.
 - **Remover colunas:** Se uma coluna tem uma proporção muito alta de valores ausentes, analisar criteriosamente a necessidade destes valores

Limpeza de Dados - Data Cleaning

Tratamento de Outliers (Valores Extremos)

São pontos de dados que se desviam significativamente de outros pontos. Podem ser erros de entrada de dados, medições incomuns ou eventos raros. Podem ser identificados através de plotagem dos dados ou algoritmos de detecção de anomalias.

- **Estratégias de Tratamento**

- **Remoção:** Remover a linha ou coluna que contém o outlier. Cuidado: pode levar à perda de informações importantes.
- ***** Transformação:** Aplicar transformações logarítmicas para reduzir o impacto dos outliers. Avaliar se não irá gerar resultados piores resultados que a remoção
- **Manter:** Em alguns casos, outliers podem ser informações valiosas (ex fraudes) e devem ser mantidos.

Limpeza de Dados - Data Cleaning

Tratamento de Dados Duplicados

Linhas idênticas ou muito semelhantes na mesma entidade que podem afetar a qualidade da análise

- **Estratégias de Tratamento**
 - Comparar colunas ou um subconjunto de colunas identificadoras, ex: ID do cliente, CPF, número de pedido, produtos de um pedido, etc...
 - Usar a função ***df.duplicated().sum()*** em Pandas (conta o número de linhas duplicadas em um DataFrame)
 - **Remoção:** Remover as duplicatas, mantendo apenas uma ocorrência. Definir qual cópia manter (primeira, última, etc.).
 - **Cancelados ou com Exclusão Lógica:** Buscar por informações em colunas do tipo para remover essas linhas, quando for o caso

Limpeza de Dados - Data Cleaning

Correção Erros de Digitação e Inconsistências de Formato

Erros humanos e/ou divergências entre as fontes de dados que podem ter diferentes métodos de entrada de dados e levam a inconsistências quando os dados são utilizados em conjunto

- **Estratégias de Tratamento**

- **Padronização de strings:** Converter para minúsculas/maiúsculas, remover espaços extras (trim),
- **Mapeamento de valores:** Substituir variações por um valor padrão (ex, "São Paulo" -> "Sao Paulo"). Pode ser feito com dicionários ou regex.
- **Conversão de tipos de dados:** Garantir que as colunas estejam no tipo correto, numérico, data, categorias,...
- **Validação de formato:** Usar expressões regulares (padrões de texto usados para descrever conjuntos de cadeias de caracteres) para validar e extrair informações de strings. (retirar . / - ...)
- **Caracteres Especiais:** remover os caracteres de final de linha, esc, (\n, \r,...)
 - **Exemplos:**
 - "São Paulo", "Sao Paulo", "sao paulo"
 - "M", "Masculino"
 - Datas em formatos diferentes: "YYYY-MM-DD", "DD/MM/YYYY"
 - Valores numéricos armazenados como texto (e.g., "1.234,56" em vez de 1234.56).

Padronização de Dados - Data Standardization

Técnicas...

Padronizar dados é o processo de transformar entradas variadas, ambíguas ou inconsistentes em formatos uniformes, de acordo com regras definidas. Isso aumenta a confiabilidade das análises, reduz erros e facilita a integração entre diferentes fontes de dados.

- Padronização de Nomes
- Padronização de Datas
- Padronização de Categorias
- Padronização de Espaços e Caracteres Especiais

Padronização de Dados - Data Standardization

Nomes e Strings

- **Problemas comuns**

- Variação no uso de maiúsculas/minúsculas (maria silva vs Maria Silva vs MARIA SILVA)
- Acentuação inconsistente (Joao vs João)
- Uso de apelidos ou abreviações (Ana Paula vs Ana P.)
- Espaços duplos ou ocultos antes/depois do nome

- **Estratégias de Tratamento**

- Definir uma convenção única de extração de dados: exemplo, primeira letra maiúscula ou todas as letras em maiúscula para campos com nome, endereço, etc...
- Remover ou padronizar acentuação
- Remover espaços em excesso no início, meio e fim do texto
- Padronizar ordem dos nomes, quando necessário (ex: nome + sobrenome)
- Criar uma tabela de equivalência de apelidos se forem permitidos (Zé → José)

Padronização de Dados - Data Standardization

Datas e Horas

- **Problemas comuns**

- Formatos variados: 01/02/2023, 2023-02-01, 1º de fevereiro de 2023
- Ambiguidade entre dia/mês (02/03/2023 é 2 de março ou 3 de fevereiro?)
- Diferença de fuso horário ou presença de horas desnecessárias

- **Estratégias de Tratamento**

- Definir e adotar um formato padrão , preferencialmente o ISO 8601 YYYY-MM-DD
- Converter todas as datas para esse formato
- Eliminar sufixos ou nomes de meses em texto ("1º de fevereiro de 2023" → 2023-02-01)
- Tratar campos de data e hora em um mesmo campo, facilita cálculos

Padronização de Dados - Data Standardization

Categorias e Domínios

- **Problemas comuns**

- Categorias escritas de formas diferentes: Feminino, feminino, F, fem, FEMININO
- Dados codificados de maneira ambígua (M, 1, Masculino)
- Presença de erros de digitação (Feminio, Feminno)

- **Estratégias de Tratamento**

- Definir um dicionário de categorias válidas (ex: M / F para sexo, SP / RJ / MG para estados)
- Mapear e corrigir variações para o padrão definido
- Eliminar duplicidades semânticas (ex: Indefinido vs Não Informado)
- **Discretização:** Transformar uma variável numérica em uma variável categórica, dividindo os valores em intervalos. Ex: Idade (contínua) para faixas etárias (categórica): 0-18 (Criança), 19-30 (Jovem Adulto), etc.
- **Label Encoding (Ou Ordinal Encoding)** : Atribui um número inteiro único a cada categoria. Exemplo "Pequeno" = 0, "Médio" = 1, "Grande" = 2

Padronização de Dados - Data Standardization

Espaços e Caracteres Especiais

- **Problemas comuns**
 - Espaços em branco antes ou depois do valor (ex: " São Paulo")
 - Espaços duplicados entre palavras ("João da Silva")
 - Espaços invisíveis (caracteres não imprimíveis como tabulação)
 - Espaços de TAB, ESC, Final de Linha, etc
- **Estratégias de Tratamento**
 - Remoção de espaços em branco desnecessários: antes, depois ou entre palavras
 - Normalização de espaçamento: manter apenas um espaço entre palavras
 - Inspeção visual e automática: utilizar relatórios de qualidade de dados para encontrar esses padrões
 - Remoção de caracteres especiais, mesmo aqueles que não estão visíveis

Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

1) Exemplos para substituição de acentuação: Mapa de Caracteres

```
def remover_acentos_substituicao(texto):
```

```
    mapa = {
```

```
        'á': 'a', 'à': 'a', 'â': 'a', 'ã': 'a', 'ä': 'a',
```

```
        'é': 'e', 'è': 'e', 'ê': 'e', 'ë': 'e',
```

```
        'í': 'i', 'ì': 'i', 'î': 'i', 'ï': 'i',
```

```
        'ó': 'o', 'ò': 'o', 'ô': 'o', 'õ': 'o', 'ö': 'o',
```

```
        'ú': 'u', 'ù': 'u', 'û': 'u', 'ü': 'u',
```

```
        'ç': 'c',
```

```
        'Á': 'A', 'À': 'A', 'Â': 'A', 'Ã': 'A', 'Ä': 'A',
```

```
        'É': 'E', 'È': 'E', 'Ê': 'E', 'Ë': 'E',
```

```
        'Í': 'I', 'Ì': 'I', 'Î': 'I', 'Ï': 'I',
```

```
        'Ó': 'O', 'Ò': 'O', 'Ô': 'O', 'Õ': 'O', 'Ö': 'O',
```

```
        'Ú': 'U', 'Ù': 'U', 'Û': 'U', 'Ü': 'U',
```

```
        'Ç': 'C'
```

```
    }
```

```
    return ''.join(mapa.get(c, c) for c in texto)
```

```
texto = "João da Conceição"
```

```
print(remover_acentos_substituicao(texto))
```

```
# Saída: Joao da Conceicao
```

Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

2) Exemplo para substituição de acentuação: Normalização Unicode (forma NFD)

```
import unicodedata
import re

def remover_acentos_unicode(texto):
    texto_normalizado = unicodedata.normalize('NFD', texto)
    texto_sem_acentos = re.sub(r'[\u0300-\u036f]', '', texto_normalizado)
    return texto_sem_acentos

texto = "André Álvares João"

print(remover_acentos_unicode(texto))

# Saída: Andre Alvares Joao
```

Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

1) Exemplos para normalização e comparação de nomes: Fuzzy Matching - Usa uma escala de 0 a 100 de similaridade

```
pip install thefuzz[speedup]
```

```
from thefuzz import fuzz  
from thefuzz import process
```

```
# Comparação direta  
nome1 = "Marcelo V Rosim"  
nome2 = "Marcelo Vicente Rosim"
```

```
similaridade = fuzz.token_set_ratio(nome1, nome2)  
print(f"Similaridade: {similaridade}%")
```

Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

2) Exemplos para normalização e comparação de nomes: Expansão de Iniciais

```
apelidos = {  
    "V": "Vicente",  
    "J": "José",  
    "M": "Maria"  
}
```

```
def expandir_iniciais(nome, mapa):  
    palavras = nome.split()  
    novas = []  
    for p in palavras:  
        if len(p) == 1 and p in mapa:  
            novas.append(mapa[p])  
        else:  
            novas.append(p)  
    return " ".join(novas)
```

```
nome = "Marcelo V Rosim"
```

```
nome_exp = expandir_iniciais(nome, apelidos)
```

```
print(nome_exp) # Marcelo Vicente Rosim
```

Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

3) Exemplos para normalização e comparação de nomes: Distância de Levenshtein

```
pip install python-Levenshtein
```

```
import Levenshtein
```

```
nome1 = "Marcelo Rosim"
```

```
nome2 = "Marcelo Vicente Rosim"
```

```
distancia = Levenshtein.distance(nome1, nome2)
```

```
similaridade = Levenshtein.ratio(nome1, nome2)
```

```
print(f"Distância: {distancia}")
```

```
print(f"Similaridade: {round(similaridade * 100)}%")
```

Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

4) Exemplos para normalização e comparação de nomes: Fonética e Distância de Jaro-Winkler

```
pip install jellyfish
```

```
import jellyfish
```

```
nome1 = "Marcelo V Rosim"
```

```
nome2 = "Marcelo Vicente Rosim"
```

```
similaridade = jellyfish.jaro_winkler_similarity(nome1, nome2)
```

```
print(f"Similaridade Jaro-Winkler: {round(similaridade * 100)}%")
```


Data Cleaning e Standardization

Padronização de Espaços e Caractere Especiais

5) Exemplos : Verificação de Encoding do arquivo e tratamento

```
import chardet
import pandas as pd

# Arquivo CSV
file_path = "file_source.csv"

# Detecta o encoding
with open(file_path, "rb") as f:
    result = chardet.detect(f.read(500)) # lê algumas linhas
    encoding_detectado = result["encoding"]

print("Encoding detectado:", encoding_detectado)

# Lê o CSV com o encoding detectado
df = pd.read_csv(file_path, encoding=encoding_detectado, on_bad_lines='skip')

print(df.head())
```

Data Cleaning e Standardization

Fluxo de Trabalho

- **Entendimento dos Dados:** Explorar os dados, entender suas características, identificar colunas, tipos de dados e potenciais problemas.
- **Identificação de Problemas:** Detectar valores ausentes, duplicatas, outliers, erros de digitação.
- **Tratamento de Valores Ausentes:** Decidir a estratégia (remover, imputar).
- **Tratamento de Duplicatas:** Remover ou ajustar.
- **Tratamento de Outliers:** Decidir se remover, transformar ou manter.
- **Correção de Inconsistências e Erros:** Padronizar strings, corrigir tipos de dados.
- **Padronização/Normalização:** Aplicar transformações de escala conforme necessário para o modelo.
- **Codificação de Variáveis Categóricas:** Transformar variáveis textuais para formatos numéricos.
- **Validação:** Após as transformações, verificar novamente a qualidade dos dados para garantir que os problemas foram resolvidos e que nenhuma nova inconsistência foi introduzida.

Data Cleaning e Standardization

Conclusão.....

A limpeza e padronização de dados são etapas pouco glamorosas, mas absolutamente essenciais em qualquer projeto de Ciência de Dados ou engenharia de dados. Investir tempo e esforço nessas fases iniciais garantirá que os resultados de suas análises e modelos sejam precisos, confiáveis e úteis.

Lembrem-se: dados precisos são a base para insights poderosos!



Enriquecimento de Dados

E o Enriquecimento de Dados....

- Objetivo : tornar os dados mais completos, contextualizados e úteis para análise e tomada de decisão.
- Processo de aprimorar e expandir dados existentes, adicionando informações relevantes de fontes internas ou externas.
- Vai além da correção de erros e da uniformização de formatos (foco da limpeza e padronização).
- Adiciona novas dimensões e atributos aos registros existentes.
- Agregar Valor e Contexto aos seus Dados

Exemplo - Dados de Cliente:

•**Antes:** Nome, Email, Histórico de Compras

•**Depois:** Nome, Email, Idade, Localização Geográfica, Histórico de Compras, Interesses

Enriquecimento de Dados

Benefícios do Enriquecimento de Dados

- **Melhor Tomada de Decisão:** Informações mais completas levam a insights mais precisos.
- **Análise Mais Profunda:** Novas variáveis permitem explorar relações e padrões ocultos.
- **Segmentação Aprimorada:** Dados enriquecidos possibilitam segmentações de clientes mais eficazes.
- **Personalização Aperfeiçoada:** Entender melhor o contexto do cliente permite ofertas e comunicações mais relevantes.
- **Previsões Mais Acertadas:** Modelos preditivos se beneficiam de um conjunto de dados mais rico.
- **Detecção de Fraudes:** Informações adicionais podem ajudar a identificar atividades suspeitas.

Enriquecimento de Dados

Fontes Comuns de Enriquecimento de Dados

- **Fontes Internas:**
 - Dados de outros sistemas da empresa (CRM, ERP,...).
 - Histórico de interações com o cliente.
 - Dados de programas de fidelidade.
- **Fontes Externas (Públicas) :**
 - Dados demográficos (IBGE, etc.).
 - Informações geográficas (APIs de geolocalização).
 - Dados socioeconômicos
- **Fontes Externas (Comerciais):**
 - Dados de terceiros (segmentos de público-alvo, informações de empresas).
 - APIs de enriquecimento (informações de contato, dados de risco, etc.).

Enriquecimento de Dados

Ferramentas e Técnicas para Enriquecimento de Dados

- **APIs de Enriquecimento de Dados:** Serviços que fornecem informações adicionais com base em dados existentes
- **Serviços de Terceiros:** Empresas especializadas em fornecer dados enriquecidos e realizar o processo.
- **Data Lakes e Data Warehouses:** Plataformas para integrar dados de diversas fontes e realizar o enriquecimento via SQL ou outras ferramentas de transformação.
- **ETL/ELT Tools** (como AWS Glue): Podem ser configuradas para buscar e integrar dados de enriquecimento durante o fluxo de dados.
- **Open Source Tools :** Bibliotecas em Python (como Pandas), geopy, GeoPandas, Shapely (Manipulação de formas geométricas, mapas, regiões), textdistance (Métricas diversas para comparação de textos (Jaro-Winkler, Levenshtein, etc.)).

Enriquecimento de Dados

Exemplos:

- **Enriquecimento de Dados Pessoais e de Contato** - Usados para validar e complementar informações sobre pessoas físicas ou jurídicas.

Clearbit API – Enriquecimento de contatos e empresas (e-mails, cargos, localização).

FullContact API – Perfil social e dados de contato a partir de e-mail, telefone ou nome.

People Data Labs API – Dados profissionais, redes sociais e localização de indivíduos.

Serasa Experian API (Brasil) – Validação de CPF/CNPJ, score e dados cadastrais (uso restrito).

ReceitaWS (Brasil) – Consulta pública de dados de CNPJs direto da Receita Federal.

- **Geolocalização e Endereços** - Enriquecem dados com latitude/longitude, bairro, CEP e até clima.

Google Maps Geocoding API – Conversão de endereços em coordenadas e vice-versa.

HERE Location API – Alternativa ao Google Maps, com geocodificação e rotas.

OpenStreetMap Nominatim API – Geocodificação gratuita usando dados OSM.

ViaCEP API (Brasil) – Consulta de endereço e bairro a partir do CEP.

IBGE APIs (Brasil) – Dados geográficos, populacionais e estatísticos de municípios.

Enriquecimento de Dados

Exemplos:

- **Dados de Empresas e Comércio** - Para enriquecer com informações de mercado, produtos e setores.

OpenCorporates API – Dados públicos de empresas no mundo.

LinkedIn API (restrita) – Perfis de empresas e funcionários.

Serasa Experian / Boa Vista SCPC – Dados financeiros e cadastrais de empresas brasileiras.

CNPJ.ws – Consulta de dados públicos de empresas via CNPJ.

- **Dados Estatísticos e Públicos** - Para enriquecer análises com indicadores econômicos, populacionais e sociais.

IBGE SIDRA API (Brasil) – Séries históricas e dados estatísticos de municípios.

Banco Central do Brasil (SGS API) – Indicadores econômicos (câmbio, inflação, etc.).

DataSUS API – Dados de saúde pública no Brasil.

INMET API – Dados meteorológicos históricos e atuais.

Enriquecimento de Dados

Exemplos:

- **Validação e Padronização de E-mails e Telefones** - Focadas em garantir que dados de contato estejam corretos e atualizados.

Hunter.io API – Validação e enriquecimento de e-mails corporativos.

ZeroBounce API – Verificação de e-mails e enriquecimento com geolocalização.

NumVerify API – Validação de números de telefone com país e operadora.



ATIVIDADE

- 1) Utilizando a base de dados fornecida como modelo aplicar as técnicas ministradas na aula para limpeza, padronização e enriquecimento de dados
- 2) Regras
 - 1) Dados Texto não devem ter acentuações
 - 2) Dados devem estar no formato exigido pelo SGBD.
 - 3) Dados Texto devem estar padronizados (maiúscula)
- 3) Ler o arquivo CSV e gerar um arquivo XLS com dados tratados
- 4) Detalhe as técnicas utilizadas para o tratamento de dados
- 5) Identificar as Métricas e KPIs relevantes ao assunto tratado pelo arquivo

Entregável:

- 1) Documento com as técnicas e etapas utilizadas no tratamento de dados e a especificação das métricas e KPIs com contextualização
- 2) Script Python utilizado para fazer o tratamento