



SÃO
PAULO
TECH
SCHOOL

Aula

Modelos Estatísticos e Análise das Relações

Prof. : Marcelo Rosim

The background is a dark, textured surface with intricate, flowing, and wavy lines in shades of gray and white. These lines create a sense of movement and depth. Scattered throughout the background are numerous small, bright white dots, some of which have a soft, out-of-focus glow, resembling bokeh or distant stars. The overall aesthetic is modern and sophisticated.

Modelos Estatísticos

Modelos Estatísticos e Análise das Relações

Em análise de dados, não basta apenas descrever os dados (estatística descritiva).



Muitas vezes precisamos *entender relações* entre *variáveis*, *prever* resultados ou *validar* hipóteses.

Para isso utilizamos *modelos estatísticos*, que são representações matemáticas simplificadas da realidade

Modelos Estatísticos e Análise das Relações


Exemplos de perguntas que podemos responder:

- Existe relação entre horas de estudo e nota em uma prova?
- O preço de um imóvel depende mais da localização ou do tamanho?
- Qual a probabilidade de um cliente cancelar a assinatura baseado em seu comportamento?



Modelos Estatísticos - *A Lógica da Predição em Dados*


Conceito



Modelos estatísticos são *fórmulas* ou *algoritmos* criados para representar *matematicamente* as *relações* entre *variáveis* dentro de um *conjunto* de *dados*.

Eles nos ajudam a *analisar* e *compreender padrões*, *entender* por que *algo acontece*, e também a *fazer previsões*, *estimando* o que *pode acontecer* no futuro.

Modelos Estatísticos - A Lógica da Predição em Dados



Conceito

Diferente de um *código* com *regras fixas* (SE $A > 10$ ENTÃO $B = 5$), os modelos estatísticos *não* fornecem uma *resposta exata* e *determinística*, mas *sim estimativas* baseadas em *probabilidade*, *acompanhadas* de um grau de *incerteza* ou *nível de confiança*.

Em resumo: os modelos estatísticos nos oferecem ferramentas para lidar com a incerteza, em vez de ignorá-la, permitindo tomar decisões mais informadas, mesmo quando os dados não são perfeitos.

Análise de Dados

Conceito



Análise de dados é o processo de *coletar, organizar, interpretar e transformar* dados brutos em *informações significativas*, com o *objetivo* de *compreender padrões, relações e tendências* que auxiliem na tomada de decisões ou na formulação de modelos preditivos.

Análise de Dados

Conceito

- **Coleta:** envolve reunir dados de diferentes fontes (bancos de dados, sensores, questionários, logs, etc.).
- **Limpeza e preparação:** remove inconsistências, valores ausentes e erros, garantindo qualidade
- **Exploração:** utiliza estatísticas descritivas (como média, mediana, moda, desvio padrão) e visualizações para entender o comportamento dos dados
- **Modelagem:** aplica métodos estatísticos ou algoritmos para identificar relações e prever comportamentos futuros.
- **Interpretação:** traduz os resultados em conclusões práticas e recomendações



Análise de Dados

Conceito



Em resumo:

A análise de dados é a *base* da *modelagem estatística*, ela fornece a *compreensão inicial* dos dados, a partir da qual os modelos são criados para *explicar* por que algo *acontece* ou *prever* o que pode *acontecer*.

Análise de Dados

Exemplo

Análise de vendas em uma loja online...

Imagine uma loja virtual que deseja entender por que alguns produtos vendem mais que outros e como aumentar o valor médio das compras.

O time de análise coleta dados de vendas, como valor, produto, região e canal de compra (site, aplicativo ou marketplace).

Ao aplicar análise de dados, identificam que as vendas feitas pelo aplicativo costumam ter valor 20% maior e que clientes das regiões Sul e Sudeste compram com mais frequência.

A partir daí, constroem um modelo estatístico que confirma a relação entre *canal de venda e valor médio*, permitindo *prever* o desempenho *das próximas campanhas*.

Com base nesses *insights*, a loja decide *investir mais em marketing no aplicativo* e *personalizar promoções por região*, aumentando suas vendas de forma planejada.

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas

Medidas de tendência central (MTC) têm como objetivo *resumir* um *conjunto de dados* em um *único valor representativo*, mostrando onde está o “*centro*” ou o *valor mais típico do conjunto*. Indicam o *ponto de equilíbrio* dos dados, ou seja, em torno de qual valor eles se concentram

- **Média** - valor médio dos dados
- **Mediana** - valor que está na posição central do conjunto de dados
- **Moda** - valor que mais se repete no conjunto de dados

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - Média

- Medida de tendência central que representa o valor médio de um conjunto de dados
- **Objetivo** : mostrar, de forma simples, como os dados se distribuem em torno de um valor central, facilitando comparações e a identificação de quem está acima ou abaixo do desempenho geral
- Obtida somando todos os valores e dividindo pelo número de elementos

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

- $\bar{X}$ → é a média (lê-se “x barra”)
- X_i → é cada valor individual do conjunto de dados
- n → é o número total de observações
- Σ → indica a soma de todos os valores

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - Média


```
import matplotlib.pyplot as plt
# Dados: nomes dos alunos e suas notas
alunos = ['Ana', 'Bruno', 'Carla', 'Diego', 'Joao', 'Jose', 'Giovanni']
notas = [5, 6, 8, 10, 4, 7, 9]
# Cálculo da média das notas
media_notas = sum(notas) / len(notas)
# Gráfico
plt.figure(figsize=(8, 5))
barras = plt.bar(alunos, notas, color='skyblue', edgecolor='black')
# Exibição da média no gráfico
plt.axhline(y=media_notas, color='red', linestyle='--', linewidth=1.5)
plt.text(len(alunos) - 0.6, media_notas + 0.2, f'Média = {media_notas:.1f}', color='red', fontsize=11, fontweight='bold')

for barra, aluno, nota in zip(barras, alunos, notas):
    plt.text(barra.get_x() + barra.get_width()/2, nota + 0.2, f'{nota}', ha='center', va='bottom', fontsize=10, fontweight='bold')
# Títulos e rótulos
plt.title('Notas de Prova dos Alunos', fontsize=14, fontweight='bold')
plt.xlabel('Alunos', fontsize=12)
plt.ylabel('Notas', fontsize=12)
```

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - Média

- Exemplo



1. Somar todas as Notas igual a 49
2. Dividir pelo numero de ocorrencias (7)

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - **Mediana**

- A mediana é uma medida de tendência central que representa o valor central de um conjunto *ordenados em ordem crescente*.
- **Objetivo:** indicar o ponto que divide o conjunto de dados ao meio, sendo útil especialmente quando há valores muito altos ou muito baixos (extremos) que podem distorcer a média.
- A mediana divide o conjunto de dados em duas partes iguais: 50% dos valores estão abaixo e 50% acima.
- Número de elementos *ímpar*, a mediana é o valor central da lista. Número de elementos *par*, a mediana é a média aritmética dos dois valores centrais

PAR

$$Md = \frac{x_{(n/2)} + x_{((n/2)+1)}}{2}$$

ÍMPAR

$$\text{Posição da Md} = \frac{n + 1}{2}$$

- $n \rightarrow$ número total de elementos no dataset
- $X_{(n/2)} \rightarrow$ posição inicial do elemento dentro do dataset
- $X_{((n/2)+1)} \rightarrow$ posição seguinte à posição inicial

Modelos Estatísticos e Análise das Relações


Medidas Estatísticas - Mediana

```
import matplotlib.pyplot as plt
# Dados originais
alunos = ['Ana', 'Bruno', 'Carla', 'Diego', 'Joao', 'Jose', 'Giovanni']
notas = [5, 6, 8, 10, 4, 7, 9]
# Ordenando alunos e notas pela nota (menor → maior)
dados_ordenados = sorted(zip(notas, alunos)) # ordena primeiro pela nota
notas_ordenadas, alunos_ordenados = zip(*dados_ordenados)
notas_ordenadas = list(notas_ordenadas)
alunos_ordenados = list(alunos_ordenados)
# Cálculo da mediana
n = len(notas_ordenadas)
if n % 2 == 0:
    mediana = (notas_ordenadas[n//2 - 1] + notas_ordenadas[n//2]) / 2
else:
    mediana = notas_ordenadas[n//2]
print(f"A mediana das notas é: {mediana}")
# Gráfico
plt.figure(figsize=(9, 5))
barras = plt.bar(alunos_ordenados, notas_ordenadas, color='skyblue', edgecolor='black')
# Rótulos de valor acima das barras
for barra, nota in zip(barras, notas_ordenadas):
    plt.text(barra.get_x() + barra.get_width()/2, nota + 0.2, f'{nota}', ha='center', va='bottom', fontsize=10)
# Linha de mediana
plt.axhline(y=mediana, color='orange', linestyle='--', linewidth=2, label=f'Mediana = {mediana:.1f}')
# Títulos e legendas
plt.title('Notas dos Alunos (Ordenadas) e Mediana da Turma')
plt.xlabel('Alunos')
plt.ylabel('Nota')
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()
```

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - **Mediana**

- Exemplo



1. Temos 7 elementos (alunos)
2. Como é um número ímpar, soma-se 1 ao número de elementos
3. Divide por 2 para localizar a posição desejada
4. A mediana é a nota que esta na posição 4

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - **Moda**

- Moda é uma medida de tendência central que representa o valor que mais se repete em um conjunto de dados
- **Objetivo** : identificar o valor mais comum ou típico de um conjunto de dados, sendo especialmente útil para análises de frequência e comportamentos predominantes nos dados.
- É o dado mais frequente, aquele que ocorre o maior número de vezes
- Quando não ocorrer elementos que se repintam, neste caso não existe moda
- Quando existir dois ou mais valores com a mesma frequência máxima, chamamos isso de distribuição bimodal (duas modas) ou multimodal (três ou mais modas).

$$Mo = X_i \text{ tal que } f_i \text{ é máximo}$$

- $X_i \rightarrow$ valor observado
- $f_i \rightarrow$ frequência (quantas vezes X_i aparece)

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - Moda

```
from statistics import multimode
import matplotlib.pyplot as plt

# Dados: nomes e notas dos alunos
alunos = ['Ana', 'Bruno', 'Carla', 'Diego', 'Eduarda', 'Felipe', 'Giovana']
notas = [8, 7, 8, 6, 5, 8, 9]

# Cálculo da(s) moda(s)
modas = multimode(notas)

# Gráfico
plt.figure(figsize=(8, 5))
barras = plt.bar(alunos, notas, color='skyblue', edgecolor='black', label='Notas dos alunos')

# Destacar barras que representam a(s) moda(s)
for barra, nota in zip(barras, notas):
    if nota in modas:
        barra.set_color('orange')

# Adicionar linha(s) e texto(s) da(s) moda(s)
for i, valor in enumerate(modas):
    plt.axhline(y=valor, color='orange', linestyle='--', linewidth=1.5)
    plt.text(len(alunos) - 0.7, valor + 0.15, f'Moda = {valor}', color='orange', fontsize=11, fontweight='bold')


# Labels sobre as barras
for barra, nota in zip(barras, notas):
    plt.text(barra.get_x() + barra.get_width()/2, nota + 0.2, f'{nota}', ha='center', va='bottom', fontsize=10, fontweight='bold')

# Títulos e rótulos
plt.title('Notas de Prova dos Alunos (Moda)', fontsize=14, fontweight='bold')
plt.xlabel('Alunos', fontsize=12)
plt.ylabel('Notas', fontsize=12)
plt.ylim(0, 10)
plt.legend([f'Moda(s): {", ".join(map(str, modas))}'])
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()
print(f"A(s) moda(s) das notas é(são): {modas}")
```

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - **Moda**

- **Exemplo**
Com um elemento




1. Identificar a nota com maior ocorrência

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas - **Moda**

- **Exemplo**

Com dois elementos



1. Identificar a nota com maior ocorrência

Modelos Estatísticos e Análise das Relações

Medidas Estatísticas

Medidas de dispersão indicam o quanto os dados se *afastam* dessa *tendência central*, o *grau de variabilidade* dentro do conjunto. São fundamentais para entender a *consistência* ou *variabilidade* de um conjunto

- **Amplitude** - diferença entre o maior e o menor valor
- **Variância** - mede a dispersão média ao quadrado
- **Desvio padrão** - mede quanto os dados se afastam da média

Modelos Estatísticos e Análise das Relações

Medidas de dispersão - **Amplitude**

- É uma medida de dispersão simples que mostra a diferença entre o maior e o menor valor de um conjunto de dados
- **Objetivo:** fornecer uma visão rápida do intervalo em que os dados se distribuem, ajudando a identificar quão amplamente os valores estão espalhados
- A amplitude mostra a distância entre o valor mínimo e o máximo, revelando o quanto os dados variam no total.

$$A = X_{\text{máx}} - X_{\text{mín}}$$

- $X_{\text{máx}}$ → maior valor do conjunto
- $X_{\text{mín}}$ → menor valor do conjunto
- A → amplitude (ou intervalo total dos dados)

Modelos Estatísticos e Análise das Relações

Medidas de dispersão - **Amplitude**


```
import matplotlib.pyplot as plt
# Dados: nomes e notas dos alunos
alunos = ['Ana', 'Bruno', 'Carla', 'Diego', 'Eduarda', 'Felipe', 'Giovana']
notas = [8, 7, 8, 6, 5, 8, 9]
# Cálculo da amplitude
amplitude = max(notas) - min(notas)
# Gráfico
plt.figure(figsize=(8, 5))
barras = plt.bar(alunos, notas, color='lightblue', edgecolor='black')
# Linhas indicando o valor mínimo e máximo
plt.axhline(y=max(notas), color='green', linestyle='--', label=f'Máxima = {max(notas)}')
plt.axhline(y=min(notas), color='red', linestyle='--', label=f'Mínima = {min(notas)}')
# Texto mostrando a amplitude
plt.text(len(alunos) - 1.5, max(notas) - 1, f'Amplitude = {amplitude}', color='purple', fontsize=11, fontweight='bold')
# Rótulos nas barras
for barra, nota in zip(barras, notas):
    plt.text(barra.get_x() + barra.get_width()/2, nota + 0.2, f'{nota}', ha='center', va='bottom', fontsize=10, fontweight='bold')
# Títulos e rótulos
plt.title('Notas de Prova dos Alunos (Amplitude)', fontsize=14, fontweight='bold')
plt.xlabel('Alunos', fontsize=12)
plt.ylabel('Notas', fontsize=12)
plt.ylim(0, 10)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()

print(f"A amplitude das notas é: {amplitude}")
```

Modelos Estatísticos e Análise das Relações

Medidas de dispersão - **Amplitude**

- Exemplo



1. Diferença entre o valor máximo e mínimo do conjunto de dados

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – Variância

- A variância é uma medida de dispersão que mostra o quanto os valores se afastam da média.
- **Objetivo:** avaliar a dispersão e consistência dos dados, ajudando a entender se os valores são próximos entre si ou muito diferentes.
- Indica o grau de variação dos dados — quanto maior a variância, mais espalhados estão os valores em relação à média.

Para uma **população**:

$$\sigma^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

Para uma **amostra**:

$$s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

- X_i → cada valor do conjunto
- $\bar{X}$ → média dos valores
- n → número de observações
- σ^2 → variância populacional
- s^2 → variância amostral

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – Variância

```
import matplotlib.pyplot as plt
from statistics import variance

# Dados: nomes e notas dos alunos
alunos = ['Ana', 'Bruno', 'Carla', 'Diego', 'Eduarda', 'Felipe', 'Giovana']
notas = [8, 7, 8, 6, 5, 8, 9]

# Cálculo da média e da variância
media = sum(notas) / len(notas)
variancia_notas = variance(notas)

# Gráfico
plt.figure(figsize=(8, 5))
barras = plt.bar(alunos, notas, color='lightblue', edgecolor='black', label='Notas dos alunos')

# Linha representando a média
plt.axhline(y=media, color='red', linestyle='--', linewidth=1.5, label=f'Média = {media:.2f}')

# Texto mostrando a variância
plt.text(len(alunos) - 1.3, media + 0.5, f'Variância = {variancia_notas:.2f}', color='purple', fontsize=11, fontweight='bold')

# Rótulos nas barras
for barra, nota in zip(barras, notas):
    plt.text(barra.get_x() + barra.get_width()/2, nota + 0.2, f'{nota}', ha='center', va='bottom', fontsize=10, fontweight='bold')


# Títulos e rótulos
plt.title('Notas de Prova dos Alunos (Média e Variância)', fontsize=14, fontweight='bold')
plt.xlabel('Alunos', fontsize=12)
plt.ylabel('Notas', fontsize=12)
plt.ylim(0, 10)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()

print(f"Média das notas: {media:.2f}")
print(f"Variância das notas: {variancia_notas:.2f}")
```

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – Variância

- Exemplo



1. Subtraímos de cada valor o valor da média
2. O resultado elevamos ao quadrado
3. Somamos os quadrados das diferenças (11,40)
4. Número de elementos -1 ($7-1=6$)
5. Variância é $11,40 / 6 = 1,9$

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – **Desvio Padrão**

- Medida de dispersão que mostra o quanto os valores se afastam da média, em unidades originais dos dados.
- **Objetivo:** avaliar a consistência e estabilidade dos dados, quanto menor o desvio padrão, mais próximas da média estão as observações; quanto maior, mais variáveis e dispersos são os valores.
- Indica o quanto, em média, cada valor difere da média, tornando fácil perceber se os dados estão concentrados ou espalhados.

Para uma **população**:

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}}$$

Para uma **amostra**:

$$s = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}}$$

- X_i → cada valor do conjunto
- $\bar{X}$ → média dos valores
- n → número de observações
- σ → desvio padrão populacional
- s → desvio padrão amostral

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – Desvio Padrão

```
import matplotlib.pyplot as plt
from statistics import mean, pstdev

# Dados: nomes e notas dos alunos
alunos = ['Ana', 'Bruno', 'Carla', 'Diego', 'Eduarda', 'Felipe', 'Giovana']
notas = [8, 7, 8, 6, 5, 8, 9]

# Cálculo da média e do desvio padrão
media = mean(notas)
desvio_padrao = pstdev(notas) # desvio padrão populacional (pode usar stdev() para amostral)

# Gráfico
plt.figure(figsize=(8, 5))
barras = plt.bar(alunos, notas, color='lightblue', edgecolor='black', label='Notas dos alunos')

# Linha representando a média
plt.axhline(y=media, color='red', linestyle='--', linewidth=1.5, label=f'Média = {media:.2f}')

# Linhas representando +1 e -1 desvio padrão
plt.axhline(y=media + desvio_padrao, color='green', linestyle=':', linewidth=1.5, label=f'+1σ = {media + desvio_padrao:.2f}')
plt.axhline(y=media - desvio_padrao, color='orange', linestyle=':', linewidth=1.5, label=f'-1σ = {media - desvio_padrao:.2f}')

# Texto mostrando o desvio padrão
plt.text(len(alunos) - 1.5, media + desvio_padrao + 0.2, f'Desvio padrão = {desvio_padrao:.2f}', color='purple', fontsize=11, fontweight='bold')

# Rótulos nas barras
for barra, nota in zip(barras, notas):
    plt.text(barra.get_x() + barra.get_width()/2, nota + 0.2, f'{nota}', ha='center', va='bottom', fontsize=10, fontweight='bold')


# Títulos e rótulos
plt.title('Notas de Prova dos Alunos (Média e Desvio Padrão)', fontsize=14, fontweight='bold')
plt.xlabel('Alunos', fontsize=12)
plt.ylabel('Notas', fontsize=12)
plt.ylim(0, 10)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()

print(f"Média das notas: {media:.2f}")
print(f"Desvio padrão das notas: {desvio_padrao:.2f}")
```

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – Desvio Padrão

- Exemplo



Média das notas: 7.29

Desvio padrão das notas: 1.28

1. Diferença da média para cada valor (Ex $9 - 7,29$)
2. O resultado elevamos ao quadrado
3. Somamos os quadrados das diferenças (11,40), até aqui, igual a variância
4. Dividimos o resultado pelo número de elementos do conjunto de dados ($11,40 / 7$) igual a **1,63**
5. O Desvio padrão é a raiz quadrada de 1,63 que é **1,28**
6. O desvio padrão **1,28** indica que, em média, as notas se desviam 1,28 pontos da média (7,29). Isso mostra que as notas estão razoavelmente próximas entre si, sem grandes variações.

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – **Boxplot**

- Boxplot, ou diagrama de caixa, é uma ferramenta gráfica que representa a distribuição dos dados em relação à mediana e aos quartis.
- Permite visualizar de forma simples a dispersão, a assimetria e a presença de valores atípicos (outliers) em um conjunto de dados.
- **Objetivo:** resumir graficamente a variação dos dados e destacar possíveis outliers, auxiliando na identificação de comportamentos anômalos e na compreensão da consistência das observações.
- Boxplot é especialmente útil antes de aplicar modelos estatísticos (como regressão), pois ajuda a identificar valores que podem distorcer os resultados.

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – **Boxplot**

```
import matplotlib.pyplot as plt
# Dados
dados = sorted([4, 5, 6, 6.5, 7, 8, 8.5, 9, 10])
n = len(dados)
# --- Cálculo manual dos quartis (sem arredondamento) ---
def calcular_quartil(dados, percent):
    pos = (n + 1) * percent / 100
    base = int(pos)
    frac = pos - base
    if base == 0:
        return dados[0]
    elif base >= n:
        return dados[-1]
    else:
        return dados[base - 1] + frac * (dados[base] - dados[base - 1])
q1 = calcular_quartil(dados, 25)
q2 = calcular_quartil(dados, 50)
q3 = calcular_quartil(dados, 75)
minimo = min(dados)
maximo = max(dados)
# Exibir valores exatos no console
print(f"Mínimo: {minimo}")
print(f"Q1: {q1}")
print(f"Mediana (Q2): {q2}")
print(f"Q3: {q3}")
print(f"Máximo: {maximo}")
# --- Gráfico Boxplot na vertical ---
fig, ax = plt.subplots()
ax.boxplot(dados, vert=True, patch_artist=True)
```

```
# Título e rótulo
plt.title('Boxplot - Distribuição dos Dados (Quartis Exatos)')
plt.ylabel('Valores')

# Adicionar os textos com os valores exatos
plt.text(1.05, minimo, f'Mín = {minimo}', va='center', color='purple')
plt.text(1.05, q1, f'Q1 = {q1}', va='center', color='blue')
plt.text(1.05, q2, f'Q2 = {q2}', va='center', color='green')
plt.text(1.05, q3, f'Q3 = {q3}', va='center', color='red')
plt.text(1.05, maximo, f'Máx = {maximo}', va='center', color='purple')

# Ajuste do eixo y
plt.ylim(minimo - 1, maximo + 1)


# Mostrar gráfico
plt.show()
```

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – **Boxplot**

- Exemplo

Mínimo: 4
Q1: 5.5
Mediana (Q2): 7.0
Q3: 8.75
Máximo: 10



1. Ordenar o conjunto de dados do menor para o maior número
2. Contar a quantidade de elementos que o conjunto de dados tem **N=9**
3. As pontas dos Bigodes são: **Mínimo = 4** e **Máximo = 10**
4. Calcular a Mediana (Q2). Temos 9 elementos, o elemento central é o de posição 5
 1. Mediana (**Q2**) indica que 50% dos dados são menores ou iguais a 7 e 50% são maiores ou iguais
5. O **Q1** é a mediana da primeira metade dos dados (4, 5, 6, 6.5), como este conjunto de dados tem 4 elementos a mediana é a média dos dois números centrais, $(5 + 6) / 2 \rightarrow Q1 = 5.5$, 25% dos dados são menores ou 5.5
6. Q3 o fim da caixa é a mediana da segunda metade dos dados (8, 8.5, 9, 10), $(8.5+9)/2 \rightarrow Q3 = 8.75$, significa que 75% dos dados são inferiores ou iguais a 8.75 e 25% são maiores

Componente do Boxplot	Valor
Qtde de elementos	9
Mínimo	4
Q1 (Início da Caixa)	5,5
Q2 Mediana (Linha Central)	7
Q3 (Fim da Caixa)	8,75
Máximo	10

Modelos Estatísticos e Análise das Relações

Medidas de dispersão – **Boxplot**

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Dados
dados = [4, 5, 6, 6.5, 7, 8, 8.5, 9, 10]

# Ordenar os dados
dados_ordenados = sorted(dados)

# Calcular os quartis
q1 = np.percentile(dados_ordenados, 25)
q2 = np.percentile(dados_ordenados, 50) # Mediana
q3 = np.percentile(dados_ordenados, 75)
iqr = q3 - q1

# Exibir resultados no console
print("Dados ordenados:", dados_ordenados)
print(f"Q1 = {q1}")
print(f"Q2 (Mediana) = {q2}")
print(f"Q3 = {q3}")
print(f"IQR = {iqr}")

# Criar Boxplot
plt.figure(figsize=(7, 5))
sns.boxplot(data=dados_ordenados, color='skyblue')


# Adicionar rótulos no gráfico
plt.text(0.15, q1, f"Q1 = {q1:.2f}", color='blue', fontsize=11, fontweight='bold')
plt.text(0.15, q2, f"Q2 (Mediana) = {q2:.2f}", color='red', fontsize=11, fontweight='bold')
plt.text(0.15, q3, f"Q3 = {q3:.2f}", color='green', fontsize=11, fontweight='bold')

# Configurações do gráfico
plt.title('Boxplot - Distribuição dos Dados com Quartis', fontsize=14, fontweight='bold')
plt.ylabel('Valores', fontsize=12)
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()

# Exibir gráfico
plt.show()
```

Cuidado ao utilizar a biblioteca numpy, ela pode arredondar os dados dos quartis

Dados ordenados: [4, 5, 6, 6.5, 7, 8, 8.5, 9, 10]
Q1 = 6.0
Q2 (Mediana) = 7.0
Q3 = 8.5
IQR = 2.5



Modelos Estatísticos e Análise das Relações

Análise de Relações

Após compreendermos como cada variável se comporta individualmente, por meio das *medidas de tendência central* (média, mediana e moda) e das *medidas de dispersão* (amplitude, variância, desvio padrão), vamos ver como duas ou mais variáveis se relacionam entre si.

Com isso, iniciamos na Análise de Relações, cujo foco é entender como o comportamento de uma variável pode influenciar outra

Modelos Estatísticos e Análise das Relações

Análise de Relações

Pausa para reflexão....

Imagine um conjunto de dados de alunos com duas variáveis:

- Horas de estudo por semana
- Nota final na disciplina

Podemos nos perguntar:

Será que quem estuda mais realmente tira notas mais altas?

Modelos Estatísticos e Análise das Relações

Análise de Relações - Correlação

É uma ferramenta estatística que nos ajuda a entender a *força* e a *direção* da relação linear entre duas variáveis. Ela nos permite responder a perguntas como: *"Existe alguma ligação entre o tempo que um aluno dedica aos estudos e sua nota final?"*

- Revela padrões de associação entre variáveis
- Indica possíveis variáveis explicativas (para regressão).
- Ajuda a eliminar redundâncias (variáveis altamente correlacionadas entre si).
- Conecta a estatística descritiva com a modelagem estatística e preditiva.

Importante: A correlação indica apenas associação, e não causalidade. Embora tempo de estudo e notas possam estar correlacionados, isso não prova que um é a causa direta do outro, apenas que eles tendem a se mover juntos.

Modelos Estatísticos e Análise das Relações

Análise de Relações - Correlação

Coeficiente de Correlação (r) varia de -1 a +1:

- **Correlação Positiva** (r próximo a +1): Indica que, à medida que uma variável aumenta, a outra também tende a aumentar.

Exemplo: quanto mais tempo o aluno estuda, maior tende a ser a sua nota.

- **Correlação Negativa** (r próximo a -1): Indica que, à medida que uma variável aumenta, a outra tende a diminuir.

Exemplo: Velocidade do carro e Tempo de viagem, mais velocidade = menos tempo


- **Correlação Nula** (r próximo a 0): Sugere que não há uma relação linear clara entre as variáveis.

Exemplo: Altura e Renda Mensal

Modelos Estatísticos e Análise das Relações

Análise de Relações – Correlação Positiva

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
# Dados
dados_pos = {
    'Aluno': [f'Aluno {i}' for i in range(1, 16)],
    'Tempo de Estudo (h)': [1, 2, 3, 3, 4, 4, 5, 5, 6, 6, 7, 8, 8, 9, 10],
    'Nota': [4, 5, 5, 6, 6, 6, 7, 7, 8, 8, 8, 8, 9, 9, 10]
}
df_pos = pd.DataFrame(dados_pos)
# Correlação
corr_pos = df_pos['Tempo de Estudo (h)'].corr(df_pos['Nota'])
# Reta de tendência
x = df_pos['Tempo de Estudo (h)']
y = df_pos['Nota']
m, b = np.polyfit(x, y, 1)
plt.scatter(x, y, color='blue')
# Adiciona rótulos dos alunos
for i, aluno in enumerate(df_pos['Aluno']):
    plt.text(x[i]+0.1, y[i]+0.05, aluno, fontsize=8)
# Reta
plt.plot(x, m*x + b, color='red', linewidth=2)
plt.title(f'Correlação Positiva (r = {corr_pos:.2f})')
plt.xlabel('Tempo de Estudo (h)')
plt.ylabel('Nota')
plt.grid(True)
plt.show()
```




O que se observa: a reta sobe quanto mais se estuda, maior tende a ser a nota.

Modelos Estatísticos e Análise das Relações

Análise de Relações – Correlação Negativa

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
# Dados
dados_neg = {
    'Aluno': [f'Aluno {i}' for i in range(1, 16)],
    'Tempo de Estudo (h)': [10, 9, 8, 8, 7, 6, 6, 5, 5, 4, 3, 3, 2, 2, 1],
    'Nota': [4, 5, 5, 5, 6, 7, 7, 7, 8, 8, 9, 9, 9, 10, 10]
}
df_neg = pd.DataFrame(dados_neg)
corr_neg = df_neg['Tempo de Estudo (h)'].corr(df_neg['Nota'])
x = df_neg['Tempo de Estudo (h)']
y = df_neg['Nota']
m, b = np.polyfit(x, y, 1)
plt.scatter(x, y, color='orange')
for i, aluno in enumerate(df_neg['Aluno']):
    plt.text(x[i]+0.1, y[i]+0.05, aluno, fontsize=8)
plt.plot(x, m*x + b, color='red', linewidth=2)
plt.title(f'Correlação Negativa (r = {corr_neg:.2f})')
plt.xlabel('Tempo de Estudo (h)')
plt.ylabel('Nota')
plt.grid(True)
plt.show()
```




O que se observa: a reta desce quanto mais se estuda, menor tende a ser a nota (relação inversa)

Modelos Estatísticos e Análise das Relações

Análise de Relações – Correlação Nula

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
# Dados
np.random.seed(42)
dados_nulo = {
    'Aluno': [f'Aluno {i}' for i in range(1, 16)],
    'Tempo de Estudo (h)': np.random.randint(1, 10, 15),
    'Nota': np.random.randint(4, 10, 15)
}
df_nulo = pd.DataFrame(dados_nulo)
corr_nulo = df_nulo['Tempo de Estudo (h)'].corr(df_nulo['Nota'])
x = df_nulo['Tempo de Estudo (h)']
y = df_nulo['Nota']
m, b = np.polyfit(x, y, 1)
plt.scatter(x, y, color='green')
for i, aluno in enumerate(df_nulo['Aluno']):
    plt.text(x[i]+0.1, y[i]+0.05, aluno, fontsize=8)
plt.plot(x, m*x + b, color='red', linewidth=2)
plt.title(f'Correlação Nula (r = {corr_nulo:.2f})')
plt.xlabel('Tempo de Estudo (h)')
plt.ylabel('Nota')
plt.grid(True)
plt.show()
```



O que se observa: os pontos estão dispersos e a reta é quase horizontal não há relação clara.

Modelos Estatísticos e Análise das Relações

Análise de Relações – Correlação - Método

- **Pearson** : mede relação linear entre as variáveis (sensível a outliers);
 - **Foco**: Relação Linear
 - **Mede**: A força e a direção de uma relação estritamente linear entre duas variáveis contínuas. Ele assume que os dados seguem, aproximadamente, uma linha reta.
 - **Contexto**: É o coeficiente mais comum. Use-o quando você espera que a relação entre as variáveis possa ser bem descrita por uma reta. Exemplo: A relação entre peso e altura em adultos, que tende a ser linear.
 - **Ponto de Atenção**: Muito sensível a outliers (valores discrepantes). Um único ponto fora do padrão pode distorcer drasticamente o valor de r .

Usado quando ambas as variáveis são numéricas e distribuídas de forma relativamente normal.

Modelos Estatísticos e Análise das Relações

Análise de Relações – Correlação - Método

- **Spearman** : mede relação monotônica (cresce ou decresce, não precisa ser linear);
 - **Foco**: Relação Monotônica (Correlação de Postos).
 - **Mede**: A força e a direção de uma relação monotônica. Uma relação monotônica é aquela em que as variáveis se movem sempre na mesma direção, mas não necessariamente de forma constante ou linear e não precisa ser uma linha reta perfeita.
 - **Como Funciona**: Em vez de usar os valores brutos dos dados, Spearman utiliza o posto (ranking) dos dados. Ele mede se, à medida que o ranking de uma variável aumenta, o ranking da outra também aumenta consistentemente.
 - **Contexto**: Ideal para: 1) Relações que não são lineares, mas são consistentes (curvas, por exemplo). 2) Quando há a presença de outliers (pois usar postos suaviza o efeito deles). 3) Variáveis ordinais (como níveis de satisfação: muito bom, bom, regular).

Escolha quando a relação é clara, mas curvada, ou quando seus dados têm outliers que você não pode remover.

Modelos Estatísticos e Análise das Relações

Análise de Relações – Correlação - Método

- **Kendall** : mede consistência de ordenação entre os pares de observações.
 - **Foco**: Consistência de Ordenação (Concordância de Pares)
 - **Mede**: A consistência da ordenação entre os pares de observações. Ele avalia a probabilidade de que, quando um par de observações é ordenado de forma diferente em uma variável, ele seja ordenado da mesma forma na outra.
 - **Como Funciona**: O r do Kendall conta o número de pares que estão “concordante” (na mesma ordem das duas variáveis) versus pares discordantes (em ordem diferente)
 - **Contexto**: É frequentemente usado como uma alternativa ao Spearman, especialmente quando o tamanho da amostra é pequeno ou quando há muitos valores empatados (laços) nos dados. É geralmente mais robusto e preferível em algumas áreas de pesquisa

Útil para testes de hipótese não paramétricos e em análise de dados com variáveis ordinais.

Modelos Estatísticos e Análise das Relações

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# === Dados base ===
dados = {
    'Aluno': [f'Aluno {i}' for i in range(1, 16)],
    'Tempo de Estudo (h)': [1, 2, 3, 3, 4, 5, 5, 6, 6, 7, 8, 8, 9, 9, 10],
    'Nota': [4, 5, 5, 6, 6, 6, 6, 7, 7, 8, 8, 8, 9, 9, 10]
}

df = pd.DataFrame(dados)

# === Cálculo das correlações ===
pearson_corr = df['Tempo de Estudo (h)'].corr(df['Nota'], method='pearson')
spearman_corr = df['Tempo de Estudo (h)'].corr(df['Nota'], method='spearman')
kendall_corr = df['Tempo de Estudo (h)'].corr(df['Nota'], method='kendall')

print("Coeficientes de Correlação:")
print(f"→ Pearson: {pearson_corr:.3f}")
print(f"→ Spearman: {spearman_corr:.3f}")
print(f"→ Kendall: {kendall_corr:.3f}")

# === Gráfico com reta e labels ===
x = df['Tempo de Estudo (h)']
y = df['Nota']


# Regressão linear (para visualizar Pearson)
m, b = np.polyfit(x, y, 1)

plt.figure(figsize=(8,6))
plt.scatter(x, y, color='blue')

# Labels
for i, aluno in enumerate(df['Aluno']):
    plt.text(x[i]+0.1, y[i]+0.05, aluno, fontsize=8)

# Reta
plt.plot(x, m*x + b, color='red', linewidth=2, label='Reta de Tendência (Pearson)')

plt.title('Correlação entre Tempo de Estudo e Nota')
plt.xlabel('Tempo de Estudo (h)')
plt.ylabel('Nota')
plt.legend()
plt.grid(True)
plt.show()
```



Modelos Estatísticos e Análise das Relações

Análise de Relações - Causalidade

Causalidade (ou causa e efeito): uma variável *influencia diretamente* a outra.

Correlação indica que duas variáveis *variam juntas*, mas *não* diz se *uma causa a outra*.

A *correlação* é uma ferramenta de *descoberta*. Ela nos aponta onde as relações existem, indicando *onde a pesquisa de causalidade* deve ser *aprofundada*.

Para provar a *causalidade*, precisamos de métodos de pesquisa mais rigorosos, como experimentos controlados ou modelos de regressão avançados, que tentam isolar o efeito de uma variável sobre a outra

Modelos Estatísticos e Análise das Relações

Análise de Relações - Causalidade


```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
np.random.seed(42)
# === Geração dos dados ===
n = 50
tempo_estudo = np.random.uniform(1, 10, n) # horas de estudo
nota = 3 + 0.6 * tempo_estudo + np.random.normal(0, 1, n) # Nota depende do tempo de estudo
df = pd.DataFrame({
    'Tempo de Estudo (h)': tempo_estudo,
    'Nota': nota
})
# === Correlação (opcional, mas didática) ===
corr_te_nota = df['Tempo de Estudo (h)'].corr(df['Nota'])
print("Correlação Tempo de Estudo ↔ Nota:", round(corr_te_nota, 2))
# === Gráfico único ===
plt.figure(figsize=(6, 4))
sns.regplot(
    x='Tempo de Estudo (h)',
    y='Nota',
    data=df,
    color='blue',
    line_kws={'color': 'red'}
)
plt.title(f'Causalidade (simulada): Tempo de Estudo → Nota\nr = {corr_te_nota:.2f}')
plt.xlabel('Tempo de Estudo (h)')
plt.ylabel('Nota')
plt.grid(True)
plt.show()
```

Modelos Estatísticos e Análise das Relações

Análise de Relações - Causalidade

Correlação Tempo de Estudo ↔ Nota: 0.85

Causalidade (simulada): Tempo de Estudo → Nota
 $r = 0.85$



O que se observa:

1. Cada ponto é um aluno
2. A reta vermelha é a tendência: conforme o tempo de estudo aumenta, a nota aumenta
3. Como os dados foram gerados fazendo a nota depender do tempo de estudo, aqui faz sentido falar em causalidade (a variável independente realmente foi usada para criar a dependente).
4. O r no título ajuda o aluno a conectar: “ah, tem correlação alta e aqui faz sentido dizer que um influencia o outro”.

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Linear Simples

Depois de identificar que duas variáveis têm correlação, o próximo passo é modelar essa relação para explicar ou até prever comportamentos.

É aqui que entra a Regressão Linear Simples, uma das ferramentas mais importantes da análise estatística.

A regressão linear simples busca encontrar uma linha que melhor descreve a relação entre duas variáveis

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Linear

Regressão linear é uma *técnica estatística* usada para *entender* e *prever* a *relação* entre duas *variáveis* — uma independente (X) e uma dependente (Y).

Depois de identificar que duas variáveis têm correlação, o próximo passo é modelar essa relação para explicar ou até prever comportamentos.

A regressão linear simples busca encontrar uma linha que melhor descreve a relação entre duas variáveis

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Linear Simples

- A Regressão Linear Simples permite modelar relações e fazer previsões baseadas em dados
- O coeficiente b indica quanto uma variável influencia a outra
- O R^2 mostra o quão bem o modelo explica os dados
- Essa técnica é a base de modelos mais complexos, como regressão múltipla e aprendizado de máquina supervisionado.

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Linear

Relação entre variáveis

- Primeiro descobrimos se existe relação entre duas variáveis:
 - Quanto mais o aluno estuda, melhor é sua nota?
 - Quando a temperatura sobe, as vendas de sorvete aumentam?
 - Se o preço do combustível sobe, as viagens diminuem?

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Linear

```
import pandas as pd
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.linear_model import LinearRegression
```

```
np.random.seed(42)
```

```
# === Geração dos dados ===
```

```
n = 50
```

```
tempo_estudo = np.random.uniform(1, 10, n)
```

```
nota = 3 + 0.6 * tempo_estudo + np.random.normal(0, 1, n)
```

```
df = pd.DataFrame({'Tempo de Estudo (h)': tempo_estudo, 'Nota': nota})
```

```
# === Regressão linear ===
```

```
X = df[['Tempo de Estudo (h)']]
```

```
y = df['Nota']
```

```
modelo = LinearRegression()
```

```
modelo.fit(X, y)
```

```
b0 = modelo.intercept_
```

```
b1 = modelo.coef_[0]
```

```
print(f"Equação: Nota = {b0:.2f} + {b1:.2f} * Tempo de Estudo")
```

```
# === Plot ===
```

```
plt.figure(figsize=(8, 6))
```

```
sns.regplot(x='Tempo de Estudo (h)', y='Nota', data=df, color='blue', line_kws={'color': 'red'})
```

```
# Ponto especial para ilustrar o erro
```

```
x_exemplo = 6
```

```
y_real = 3 + 0.6 * x_exemplo + np.random.normal(0, 1, 1)[0] # simula um ponto real
```

```
y_prev = b0 + b1 * x_exemplo # valor previsto pela reta
```

```
# Linha vertical do erro (resíduo)
```

```
plt.plot([x_exemplo, x_exemplo], [y_prev, y_real], 'k--', lw=2)
```

```
plt.scatter(x_exemplo, y_real, color='green', s=80, label='Valor real (ponto observado)')
```

```
plt.scatter(x_exemplo, y_prev, color='red', s=80, label='Valor previsto pela reta')
```

```
# === Labels explicativos ===
```

```
plt.text(1, b0 + 0.2, 'β0 (Intercepto)\nNota quando tempo de estudo = 0', fontsize=10, color='black')
```

```
plt.text(8, b0 + b1*8 + 0.3, 'β1 (Inclinação)\nVariação da nota a cada hora estudada', fontsize=10, color='red')
```

```
plt.text(x_exemplo + 0.3, (y_prev + y_real)/2, 'ε (Erro)', fontsize=10, color='purple')
```

```
# Título e eixos
```

```
plt.title(f"Regressão Linear Simples: Nota = {b0:.2f} + {b1:.2f} × Tempo de Estudo", fontsize=12)
```

```
plt.xlabel('Tempo de Estudo (h)')
```

```
plt.ylabel('Nota')
```

```
plt.legend()
```

```
plt.grid(True)
```

```
plt.show()
```

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Linear Múltipla

A regressão linear múltipla é uma técnica estatística utilizada para modelar a relação linear entre uma variável dependente ou resposta (desfecho), geralmente denotada por Y e duas ou mais variáveis independentes ou explicativas (preditoras), denotadas por $X_1, X_2, \dots, X_k$.

O objetivo é encontrar uma equação que melhor descreva como as variáveis preditoras se relacionam com a variável de desfecho e, assim, poder prever o valor de Y a partir dos valores de $X_1, X_2, \dots, X_k$.

Modelos Estatísticos e Análise das Relações


Regressão Linear Múltipla

```
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
# Dados
dados = pd.DataFrame({
    'horas_estudo': [1, 2, 3, 4, 5, 6, 7],
    'frequencia': [60, 65, 70, 75, 80, 85, 90],
    'nota_prova': [50, 55, 60, 68, 73, 78, 85]
})
# Define variáveis independentes (X) e dependente (Y)
X = dados[['horas_estudo', 'frequencia']]
Y = dados['nota_prova']
# Adiciona constante (intercepto)
X = sm.add_constant(X)
# Cria e ajusta o modelo
modelo_multiplo = sm.OLS(Y, X).fit()
# Adiciona valores previstos
dados['nota_prevista'] = modelo_multiplo.fittedvalues
# =====
# Gráfico com frequência em cor
# =====
```

```
plt.figure(figsize=(8, 6))
scatter = plt.scatter(
    x=dados['horas_estudo'],
    y=dados['nota_prova'],
    c=dados['frequencia'],
    cmap='viridis',
    s=100,
    edgecolor='k')
# Linha das previsões
sns.lineplot(
    x='horas_estudo',
    y='nota_prevista',
    data=dados,
    color='red',
    label='Linha prevista')
plt.title('Regressão Linear Múltipla (Nota ~ Horas de Estudo + Frequência)')
plt.xlabel('Horas de Estudo')
plt.ylabel('Nota na Prova')
plt.colorbar(scatter, label='Frequência (%)')
plt.legend()
plt.grid(True)
plt.show()
# Comparação real x previsto
print("\nComparação entre notas reais e previstas:")
print(dados[['horas_estudo', 'frequencia', 'nota_prova', 'nota_prevista']])
```

Modelos Estatísticos e Análise das Relações

Análise de Relações – Regração Multipla



Comparação entre notas reais e previstas:

	horas_estudo	frequencia	nota_prova	nota_prevista
0	1	60	50	49.428571
1	2	65	55	55.285714
2	3	70	60	61.142857
3	4	75	68	67.000000
4	5	80	73	72.857143
5	6	85	78	78.714286
6	7	90	85	84.571429

- Cada ponto representa um aluno.
- A **cor** mostra a **frequência** (amarelo = mais alta, azul = mais baixa).
- A **linha vermelha** mostra a tendência prevista pelo modelo.

- eixo X → horas de estudo
- eixo Y → nota
- cor → frequência

Modelos Estatísticos e Análise das Relações

Análise de Relações

Conclusão

- Correlação mostra se há relação
- Regressão simples $\rightarrow$ uma causa, um efeito
- Regressão múltipla $\rightarrow$ várias causas, um efeito



Prática

- Dado o conjunto de dados desempenho_alunos.csv
- Apresentar a análise em formato gráfico:
 - Média
 - Mediana
 - Moda
 - Amplitude
 - Variância
 - Desvio Padrão
 - BoxPlot
 - Correlação
 - Regressão Linear
- Apresentar os Gráficos e o fazer a ***Interpretação dos Resultados*** em arquivo PDF

Agradeço
a sua atenção!

Marcelo Rosim

marcelo.rosim@sptech.school

SÃO
PAULO
TECH
SCHOOL