



SÃO
PAULO
TECH
SCHOOL

Aula

Dados Não Estruturados

Prof. : Marcelo Rosim

Dados Estruturados X Dados Não Estruturados

Os dados estruturados têm modelo de dados estrito e predefinido.

- Exemplo: banco de dados transacional

Os dados não estruturados não seguem um formato fixo ou pré-definido.

- Exemplos: comentários em uma rede social, corpo de e-mail, imagens, áudios...

Após a captura dos dados não estruturados, como podemos transformar linguagem natural em dados analisáveis?

- Os dados não estruturados apresentam diversos desafios, como ausência de padronização, complexidade semântica e escalabilidade.

Vamos acompanhar o tratamento desses 2 comentários (não estruturados) em cada etapa:

1. “O produto é excelente!!! Chegou rápido e bem embalado 😄”
2. “Atendimento ruim, o pedido demorou demais e veio errado...”

Dados Não Estruturados

Tratamento dos dados

Uma etapa essencial após a coleta dos dados não estruturados é o seu tratamento.

Limpeza de Dados

Fazer a normalização dos dados.

Exemplos:

- Remoção de pontuações, números...
- Padronização (letras minúsculas, sem acentos).

1. “O produto é excelente!!! Chegou rápido e bem embalado 😊”
2. “Atendimento ruim, o pedido demorou demais e veio errado...”

1. “o produto e excelente chegou rapido e bem embalado”
2. “atendimento ruim o pedido demorou demais e veio errado”

Dados Não Estruturados

Tratamento dos dados

Tokenização

Reduzir os dados em tokens (unidade mínima de análise).

Exemplo:

- Um vetor de palavras é criado a partir da tokenização.

1. “o produto e excelente chegou rápido e bem embalado”
2. “atendimento ruim o pedido demorou demais e veio errado”

1. [“o”, “produto”, “e”, “excelente”, “chegou”, “rapido”, “e”, “bem”, “embalado”]
2. [“atendimento”, “ruim”, “o”, “pedido”, “demorou”, “demais”, “e”, “veio”, “errado”]

Dados Não Estruturados

Tratamento dos dados

Remoção de Stopwords

Eliminar palavras sem significado analítico.

Exemplos de palavras:

- “o”, “e”, “de”, “a”...

1. [“o”, “produto”, “e”, “excelente”, “chegou”, “rapido”, “e”, “bem”, “embalado”]
2. [“atendimento”, “ruim”, “o”, “pedido”, “demorou”, “demais”, “e”, “veio”, “errado”]

1. [“produto”, “excelente”, “chegou”, “rapido”, “bem”, “embalado”]
2. [“atendimento”, “ruim”, “pedido”, “demorou”, “demais”, “veio”, “errado”]

Dados Não Estruturados

Tratamento dos dados

Lematização ou Stemming

Reduzir palavras à sua forma base (raiz ou lema). Essa etapa ajuda a reduzir variabilidade semântica.

Exemplo:

- aprendendo, aprendido, aprendizado → aprender

1. ["produto", "excelente", "chegou", "rapido", "bem", "embalado"]
2. ["atendimento", "ruim", "pedido", "demorou", "demais", "veio", "errado"]

1. ["produto", "excelente", "chegar", "rapido", "bem", "embalar"]
 2. ["atendimento", "ruim", "pedido", "demorar", "demais", "vir", "errado"]
- 

Dados Não Estruturados

Modelagem Analítica

O objetivo é transformar dados tratados em informações úteis, aplicando técnicas estatísticas e de aprendizado de máquina para extrair padrões, sentimentos, temas ou previsões.

Para isso, existem várias técnicas. Qual usar?

O tratamento dos dados e a escolha da modelagem analítica depende do objetivo final.

Dados Não Estruturados

Modelagem Analítica - Exemplos

Objetivo	Técnica Analítica	Aplicação Prática
Explorar ou resumir textos	TF-IDF / Bag of Words	Encontrar termos mais usados em avaliações
Classificar opiniões	Análise de Sentimento	Identificar satisfação de clientes
Agrupar conteúdos similares	Clustering (K-Means, LDA)	Agrupar notícias por assunto
Extraír significados	Word Embeddings (Word2Vec, BERT)	Entender contexto semântico
Representar frases/documentos inteiros com contexto	Sentence Embeddings (BERT, SBERT, MiniLM)	Busca semântica avançada
Descobrir temas escondidos em muitos textos	Topic Modeling (LDA, NMF)	Segmentação de clientes, análise de reclamações...
Rotular textos automaticamente com precisão	Classificação com Transformers	Fine-tuning de modelos como BERT, DistilBERT...

Exemplos de bibliotecas Python utilizadas: sklearn, nltk, spacy, gensim, transformers, pandas, matplotlib, seaborn

Dados Não Estruturados

Modelagem Analítica

TF-IDF

Pondera as palavras considerando frequência dentro do documento e raridade nos demais documentos, destacando termos realmente representativos.

Por que é útil:

Ajuda a identificar palavras que diferenciam um texto.

```
frase_1 = ["produto", "excelente", "chegar", "rapido", "bem", "embalar"]  
frase_2 = ["atendimento", "ruim", "pedido", "demorar", "demais", "vir", "errado"]
```



Frase 1 (termos mais relevantes): rápido (0.408) ; produto (0.408) ; bem (0.408)

Frase 2 (termos mais relevantes): vir (0.378) ; ruim (0.378) ; pedido (0.378)

Dados Não Estruturados

Modelagem Analítica

Análise de Sentimento

Classifica textos como positivos, negativos ou neutros, com base nas palavras. Depende de dicionário ou IA pré-treinada (limitações de humor, ironia...).

Por que é útil:

Permite medir a satisfação ou o humor geral de um conjunto de comentários.

```
frase_1 = ["produto", "excelente", "chegar", "rapido", "bem", "embalar"]
```

```
frase_2 = ["atendimento", "ruim", "pedido", "demorar", "demais", "vir", "errado"]
```



Sentimento frase 1: positivo

Sentimento frase 2: negativo

Dados Não Estruturados

Modelagem Analítica

Clustering

Agrupa textos automaticamente com base em similaridades. Não tenta descobrir temas ocultos, apenas junta o que é parecido matematicamente (distância em vetores).

Por que é útil:

Permite identificar agrupamentos/padrões.

```
frase_1 = ["produto", "excelente", "chegar", "rapido", "bem", "embalar"]  
frase_2 = ["atendimento", "ruim", "pedido", "demorar", "demais", "vir", "errado"]
```



Frase 1 = Cluster → 0

Frase 2 = Cluster → 1

Dados Não Estruturados

Modelagem Analítica

Word Embeddings

Convertem palavras em vetores numéricos que carregam significado (semântica).
Palavras com sentidos parecidos ficam próximas no espaço vetorial.

Por que é útil:

Permite medir similaridade, olhando para significado e contexto (bases mais modernas).

```
frase_1 = ["produto", "excelente", "chegar", "rapido", "bem", "embalar"]  
frase_2 = ["atendimento", "ruim", "pedido", "demorar", "demais", "vir", "errado"]
```



Frase 1: $[[0.12, -0.55, 0.87, 0.03, 0.44], [0.91, 0.22, -0.10, 0.77, 0.35], \dots]$

Frase 2: $[[-0.44, 0.77, 0.01, 0.34, 0.12], [0.92, -0.33, 0.66, 0.01, 0.09], \dots]$

Conclusão (Etapas) - Dados Não Estruturados

Nome	Objetivo	Exemplos
Coleta	Obter dados brutos	API, scraping, uploads
Tratamento / Preparação (Pré-processamento)	Limpar e organizar	Limpeza, tokenização, lematização
Modelagem Analítica	Extrair padrões e significados	TF-IDF, LDA, BERT, Clustering
Interpretação / Resultados	Gerar insights e ações	Dashboards, relatórios, decisões



Prática

- Definam os dados não estruturados a serem utilizados no projeto de PI.
- Apliquem técnicas de tratamento/preparação adequadas a esse tipo de dado.
- Escolham, descrevam e especifiquem pelo menos 1 modelagem analítica que agregaria valor à base definida.
- Atividade deve ser feita em Grupo.
- Entregável: Arquivo PDF, com o conjunto de dados, scripts python utilizados, técnicas utilizadas e definição de pelo menos 1 modelagem analítica que seria adequada.

Agradeço
a sua atenção!

Marcelo Rosim

marcelo.rosim@sptech.school

SÃO
PAULO
TECH
SCHOOL