



SÃO
PAULO
TECH
SCHOOL

Aula

Técnicas de EDA

(Análise Exploratória de Dados)

Prof. : Marcelo Rosim

Técnicas de EDA

(Exploratory Data Analysis)

Técnicas de EDA

EDA - Análise Exploratória de Dados é por onde iniciamos a jornada na ciência de dados.

Explorando e entendendo o conjunto de dados antes de partir para a criação de modelos, na EDA é onde identificamos padrões, erros e relações entre as variáveis

Foca em responder: *O QUE HÁ NESTES DADOS?*
COMO POSSO USÁ-LOS?

Técnicas de EDA

Pense na EDA como uma investigação inicial do conjunto de dados.

Antes de tentar prever o futuro, você precisa entender o que os dados dizem sobre o passado e o presente.

💡 *EDA é a fase em que deixamos os dados “falarem”*

Técnicas de EDA - Importância

- Evitar erros na análise por dados incorretos
- Permitir descobrir relações ocultas entre variáveis
- Ajudar a gerar hipóteses e perguntas que guiarão as próximas etapas
- É a base para qualquer modelo preditivo confiável



“Se você colocar dados ruins em um modelo, vai obter resultados ruins. A EDA é o filtro de qualidade da análise.”

Técnicas de EDA - Importância

Exemplo Prático:

Vamos supor que a EDA revelou que 70% dos seus dados de '*Renda*' estão ausentes, qualquer modelo preditivo de crédito que use essa variável será inútil.

Na EDA a primeira ação é corrigir a fonte dos dados ou mudar o foco da análise.

The background is a dark, monochromatic abstract composition. It features a series of thin, light-colored lines that flow and curve across the frame, creating a sense of movement and depth. These lines are interspersed with numerous small, bright white dots and larger, fainter circular bokeh-like shapes. The overall effect is reminiscent of a cosmic or digital landscape, with the lines suggesting paths or data streams and the particles representing individual points of light or data. The lighting is soft and diffused, highlighting the intricate patterns of the lines and the scattered nature of the particles.

Python

Técnicas de EDA – Etapas

- **Análise de Estrutura e Tipos:** Inspeccionar as variáveis, tipos (*numérico, texto, data*), *nulos* e contadores.

Exemplo `info()`, `isnull()`, `value_counts()`

- Quantas linhas e colunas existem
- Tipos de dados (texto, número, datas);
- Se existem valores ausentes;
- Se há colunas categóricas importantes para agrupar análises

Resultado da Análise

- Tipos estão coerentes com o significado de cada variável (*data, categoria, numéricas*).
- Não há, nessa visão geral, indício de problema de tipo (*ex.: preço como texto, data como string etc.*).

Técnicas de EDA – Etapas

- **Estatísticas Descritivas:** É nesta etapa que iremos resumir numericamente o comportamento das variáveis.

Exemplo `describe()`, `median()`, `mode()`, `var()`, `std()`, `min()` e `max()`, `quantile()`

- Os valores estão concentrados ou espalhados?
- Há presença de valores extremos?
- O comportamento está coerente com a regra de negócio?
- Existe variação suficiente para justificar modelagem futura?
- Se existem valores ausentes;
- Se há colunas categóricas importantes para agrupar análises

Resultado da Análise

- Quantidade vendida e avaliações apresentam comportamento estável, sem valores incompatíveis com o contexto
- Não há, nessa visão por produto, indício de problema estrutural nos dados (ex.: preços fora de faixa, quantidades negativas, avaliações inválidas).

Técnicas de EDA – Etapas

- **Análise de Distribuição:** Objetivo de entender como os valores de uma variável se espalham ao longo do seu domínio.

Exemplo `histplot()`, `plt.hist()`, `boxplot()`,...

- Ajuda a identificar erros ou distorções de dados (digitação, truncamento, limites artificiais);
- Fornece evidências visuais para qualidade e coerência dos dados.
- Existem caudas longas (muitos valores extremos)?
- Há valores atípicos (outliers) que fogem completamente do padrão?
- O comportamento se aproxima de uma distribuição normal ?

Resultado da Análise

- As variáveis ***Preco***, ***Qtd_Vendida*** e ***Avaliacao*** têm comportamento coerente produto a produto.
- Não há indícios de: tipos errados, faixas totalmente fora da realidade, produtos “estranhos” com comportamento incompatível com o restante da base

Técnicas de EDA – Etapas

- **Identificação de Outliers:** Detectar pontos que fogem significativamente do padrão da distribuição dos dados.

Exemplo `boxplot()`

- Influenciar modelos estatísticos e de machine learning;
- indicar erros de coleta, digitação ou integração de sistemas;
- revelar comportamentos raros, mas reais (insights valiosos).
- Indícios de mudança de comportamento (ex.: ruptura de estoque, sazonalidades, anomalias)

Resultado da Análise

- Preço Unitário por Produto revela forte variabilidade e muitos outliers, indicando que a relação Preço/Quantidade pode ter inconsistências
- Verificar junto a área de negócio, a existência de promoções, ou outras ações para a variabilidade do valor unitário

Técnicas de EDA – Etapas

- **Análise de Correlação:** Possibilita identificar relações entre variáveis numéricas.

Exemplo `corr()` matriz de correlação, `heatmap()` visualização da matriz

- Identificar possíveis problemas na base (ex.: valores fora da regra)
- Escolher variáveis relevantes para modelagem
- Evitar colinearidade (variáveis que dizem a mesma coisa)
- Detectar dependências estruturais entre variáveis
- +1 relação positiva (uma aumenta, a outra também), -1 relação negativa (uma aumenta, a outra diminui) e 0 → sem relação clara

Resultado da Análise

- Para cada produto, não há evidência de relação linear forte entre Preço e Quantidade Vendida
- A maioria dos coeficientes fica próxima de zero, indicando relações fracas ou inexistentes;

Técnicas de EDA – Etapas

- **Análise de Valores Ausentes:** identificar e tratar valores ausentes antes de modelagens ou análises avançadas

Exemplo `isnull()`, `fillna()`

- Remoção de Linhas : Excluir a linha inteira. Usar apenas quando a porcentagem de dados ausentes for muito baixa (*geralmente menos de 5%*) para evitar perda significativa de dados valiosos.
- Remoção de Colunas: Excluir a variável se a porcentagem de ausentes for muito alta (*geralmente acima de 50-70%*), pois o custo de imputação é maior que o valor do insight que ela pode fornecer.

Resultado da Análise

- O dataset está completamente íntegro, não há nulos em nenhuma coluna.

Técnicas de EDA

Conclusão

- EDA é o momento de descoberta dos dados.
- Envolve analisar, visualizar e interpretar de forma crítica.
- Cada gráfico e métrica deve levar a uma decisão prática.



“EDA não é apenas código, é raciocínio analítico sobre os dados.”



Prática

Censo 2022 – Estado de São Paulo

O Governo do Estado de São Paulo recebeu os resultados do Censo 2022 do IBGE, contendo informações sobre:

- Total de domicílios ocupados
- Total de moradores
- Média de moradores por domicílio
- Identificação do município
- Dados agregados por UF e municípios

A Secretaria de Planejamento solicitou aos analistas uma primeira investigação dos dados, com foco em:

- Verificar a qualidade e consistência da base
- Detectar comportamentos atípicos

Prática

Censo 2022 – Estado de São Paulo

- 1) Utilizar as técnicas de EDA para analisar a base de dados e identificar oportunidade de melhoria para que a base fique íntegra para seguir para modelagem e análise.
- 2) Atividade deve ser feita em Grupo
- 3) Entregável: Arquivo PDF, com o conjunto de dados, scripts python utilizados, técnicas utilizadas para corrigir possíveis erros, se for o caso.

Agradeço
a sua atenção!

Marcelo Rosim

marcelo.rosim@sptech.school

SÃO
PAULO
TECH
SCHOOL